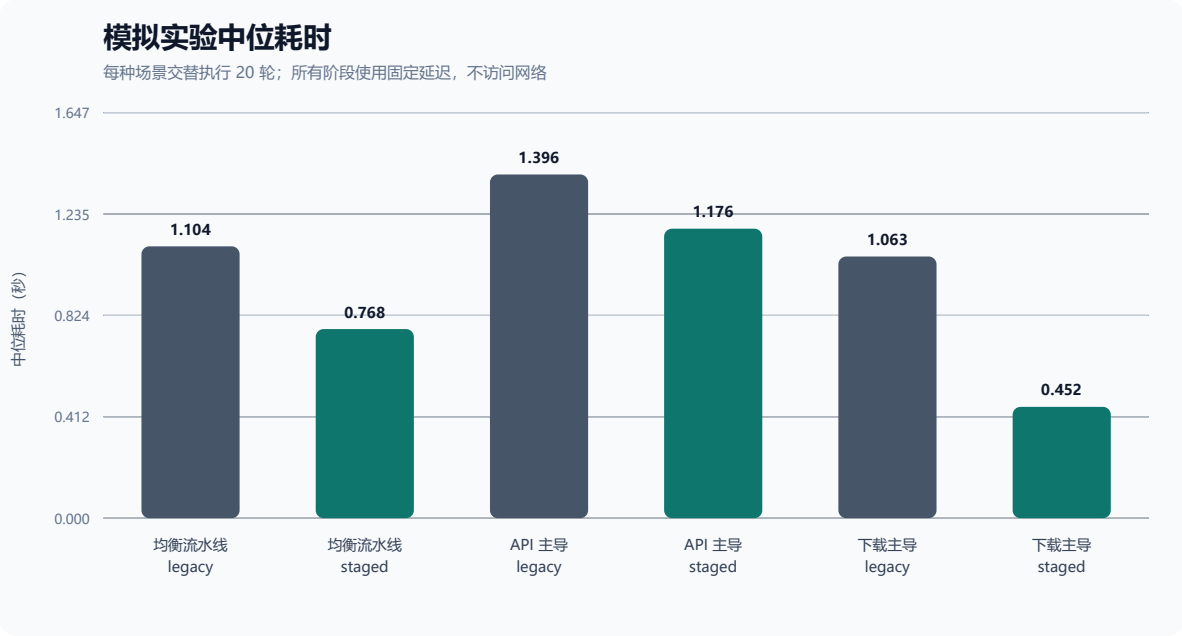
论文流水线分阶段并发：可控模拟实验报告

md文件位置：BUAA_Paper_Research_Agent\outputs\benchmarks\simulated\simulation-20261023-191217-953900

> 本实验完全离线：不下载真实 PDF、不调用模型 API。它验证调度算法本身，不能替代真实网络环境测试。



- 生成时间：2026-10-23T11:14:16.940165+00:00
- 论文清单：`D:\BUAA\homework\26-27-Autumn\ai\BUAA_Paper_Research_Agent\benchmark_manifest_10.json`（10 篇，与真实 Benchmark 相同）
- 每个场景轮数：20 轮 legacy + 20 轮 staged
- 执行顺序：奇数轮 legacy→staged，偶数轮 staged→legacy
- 计时：`time.perf_counter()` 单调时钟
- 随机性：无随机延迟；每篇论文使用固定、可复现的耗时倍率

模拟配置

场景	下载/篇	转换/篇	总结/篇	目的
均衡流水线	0.040s	0.015s	0.120s	三个阶段均有可观耗时，检验流水线重叠收益
API 主导	0.010s	0.005s	0.200s	总结远慢于其他阶段，模拟当前真实系统瓶颈
下载主导	0.120s	0.010s	0.030s	下载占主导，检验下载并发 4 的收益

三种实验设置说明

三个场景使用完全相同的 10 篇论文、论文顺序、并发参数和调度代码，仅改变下载、转换、总结三个阶段的固定模拟耗时。每篇论文还使用 0.80 ~ 1.25 的固定耗时倍率，用来模拟论文大小和处理难度差异；同一篇论文在 legacy 与 staged 中的倍率完全相同，因此不会偏向任何模式。

1. 均衡流水线

- 基础耗时：下载 40ms、转换 15ms、总结 120ms。
- 单篇三个阶段的基础总耗时为 175ms，其中下载约占 22.9%、转换约占 8.6%、总结约占 68.6%。
- 这里的“均衡”不是指三个阶段耗时完全相等，而是指下载和转换的占比仍然足以影响总耗时，三个阶段之间存在可利用的流水线重叠空间。
- 它模拟一般论文处理任务：API 总结最慢，但 PDF 获取和解析同样不是可以忽略的瞬时操作。
- 预期现象：staged 可以在前两篇论文总结时继续下载和转换后续论文，从而减少 legacy 整篇占槽造成的队头阻塞。

2. API 主导

- 基础耗时：下载 10ms、转换 5ms、总结 200ms。
- 单篇基础总耗时为 215ms，其中总结约占 93.0%，下载和转换合计仅占约 7.0%。
- 它模拟真实系统中模型响应远慢于 PDF 下载和文本转换的情况，也是当前真实 Benchmark 最接近的抽象场景。
- 两种模式的有效总结并发都为 2，因此 staged 无法提高最主要瓶颈的并发上限，只能让很短的下载和转换提前完成。
- 预期现象：staged 仍可能因减少整篇调度等待而略有收益，但改善率应明显低于下载主导场景；如果外部 API 波动很大，这部分收益可能被噪声覆盖。

3. 下载主导

- 基础耗时：下载 120ms、转换 10ms、总结 30ms。
- 单篇基础总耗时为 160ms，其中下载占 75.0%，转换占 6.25%，总结占 18.75%。
- 它模拟 PDF 较大、论文站点响应较慢，但下载服务允许并行请求的情况。这里故意不模拟 arXiv 的强制串行限速，用于单独测量下载并发从 2 提升到 4 的调度上限。
- legacy 最多只有两篇论文进入完整流程，因此同时下载数量不会超过 2；staged 可以使用 4 个下载槽，并让已下载论文继续进入转换和总结阶段。
- 预期现象：这是最有利于 staged 的场景，用来验证下载并发和阶段重叠能够带来的理论收益，而不是代表当前 5 篇 arXiv 测试集的真实下载表现。

三种设置的核心区别

对比项	均衡流水线	API 主导	下载主导
主要耗时来源	总结为主，下载/转换仍不可忽略	总结占绝对主导	下载占主导
staged 可利用的能力	三阶段重叠	主要是减少队头阻塞	下载并发 4 + 阶段重叠
预期收益	中等	较小	最大
对真实系统的含义	展示一般流水线收益	最接近当前 API 瓶颈	展示下载可并行时的上限

因此，这三个场景不是三套不同算法，而是对同一套调度算法进行敏感性分析：通过改变瓶颈所在阶段，观察 staged 在什么条件下有效、收益何时受限。

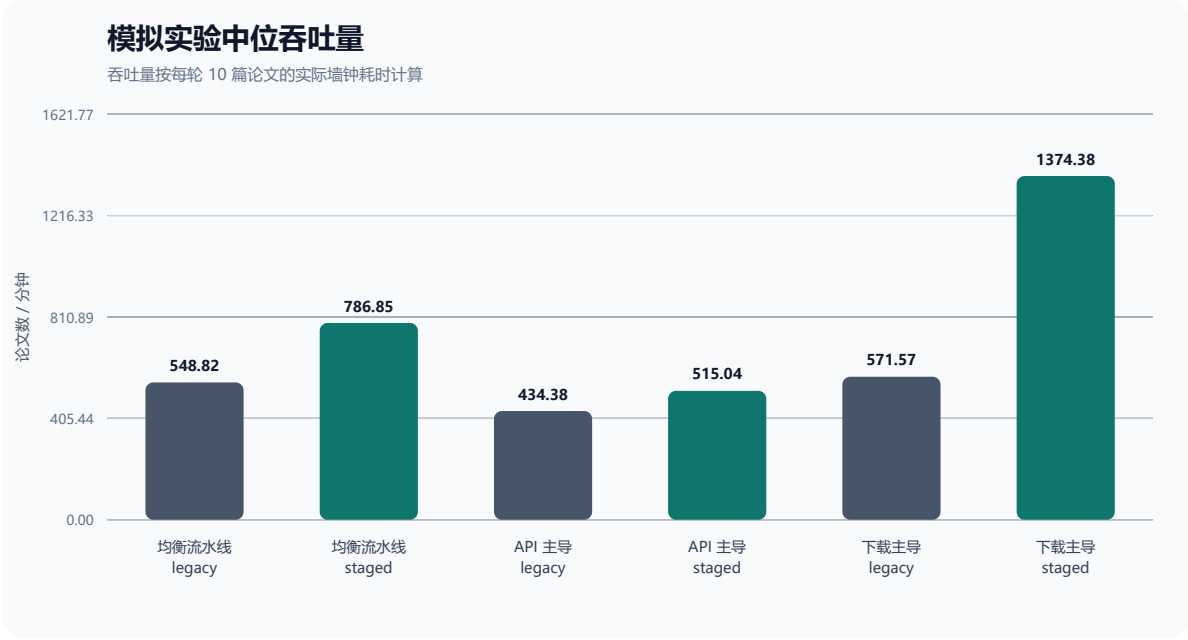
流水线并发参数：

参数	值
legacy_concurrency	2
download_concurrency	4
convert_concurrency	1
summary_concurrency	2
max_in_flight	8

总体结果

场景	Legacy 中位数	Staged 中位数	改善率	Legacy 范围	Staged 范围	最终失败
均衡流水线	1.104s	0.768s	30.44%	1.056–1.195s	0.711–0.832s	0
API 主导	1.396s	1.176s	15.78%	1.338–1.439s	1.096–1.253s	0
下载主导	1.063s	0.452s	57.46%	0.984–1.187s	0.408–0.592s	0

改善率 = `(Legacy 中位耗时 - Staged 中位耗时) / Legacy 中位耗时 × 100%`。



实际并发上限

以下是全部轮次中观测到的最大同时执行数量：

场景	模式	下载	转换	总结	整篇调度等待中位数
均衡流水线	legacy	2	1	2	3.657s
均衡流水线	staged	4	1	2	0.000s
API 主导	legacy	2	1	2	4.506s
API 主导	staged	4	1	2	0.000s
下载主导	legacy	2	1	2	3.501s
下载主导	staged	4	1	2	0.000s

各场景阶段等待

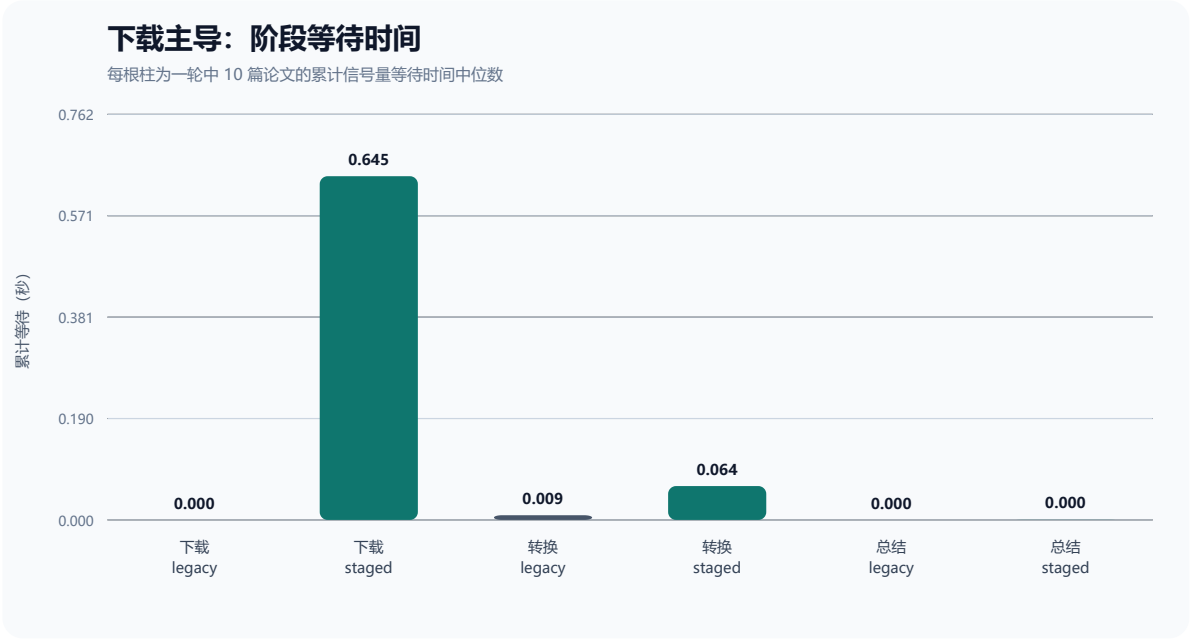
均衡流水线



API 主导



下载主导


下载主导：阶段等待时间
每根柱为一轮中 10 篇论文的累计信号量等待时间中位数
累计等待（秒）
0.762
0.571
0.381
0.190
0.000
0.000
0.645
0.009
0.064
0.000
0.000
下载 legacy
下载 staged
转换 legacy
转换 staged
总结 legacy
总结 staged

各轮结果

场景	轮次	Legacy(s)	Staged(s)	本轮改善率
均衡流水线	1	1.101	0.738	32.99%
均衡流水线	2	1.093	0.747	31.62%
均衡流水线	3	1.078	0.768	28.75%
均衡流水线	4	1.068	0.781	26.88%
均衡流水线	5	1.122	0.780	30.43%
均衡流水线	6	1.121	0.747	33.33%
均衡流水线	7	1.073	0.768	28.49%
均衡流水线	8	1.122	0.760	32.21%
均衡流水线	9	1.076	0.749	30.40%
均衡流水线	10	1.074	0.782	27.25%
均衡流水线	11	1.058	0.711	32.80%
均衡流水线	12	1.061	0.763	28.07%
均衡流水线	13	1.056	0.768	27.27%
均衡流水线	14	1.111	0.764	31.25%
均衡流水线	15	1.107	0.818	26.09%
均衡流水线	16	1.168	0.796	31.85%
均衡流水线	17	1.195	0.832	30.43%
均衡流水线	18	1.130	0.820	27.38%
均衡流水线	19	1.168	0.785	32.82%
均衡流水线	20	1.195	0.809	32.29%
API 主导	1	1.354	1.169	13.67%
API 主导	2	1.375	1.233	10.35%
API 主导	3	1.360	1.170	14.00%
API 主导	4	1.424	1.242	12.79%
API 主导	5	1.439	1.170	18.67%
API 主导	6	1.406	1.098	21.91%
API 主导	7	1.403	1.188	15.28%
API 主导	8	1.343	1.096	18.34%
API 主导	9	1.409	1.132	19.67%
API 主导	10	1.408	1.253	11.05%

场景	轮次	Legacy(s)	Staged(s)	本轮改善率
API 主导	11	1.394	1.191	14.61%
API 主导	12	1.356	1.235	8.93%
API 主导	13	1.355	1.160	14.36%
API 主导	14	1.380	1.194	13.43%
API 主导	15	1.410	1.120	20.58%
API 主导	16	1.398	1.192	14.70%
API 主导	17	1.401	1.205	13.96%
API 主导	18	1.362	1.172	13.94%
API 主导	19	1.419	1.152	18.81%
API 主导	20	1.338	1.179	11.88%
下载主导	1	1.009	0.422	58.16%
下载主导	2	1.068	0.458	57.14%
下载主导	3	1.038	0.450	56.67%
下载主导	4	1.032	0.469	54.58%
下载主导	5	1.062	0.408	61.57%
下载主导	6	1.071	0.443	58.66%
下载主导	7	1.064	0.455	57.20%
下载主导	8	1.057	0.454	57.02%
下载主导	9	1.095	0.471	56.96%
下载主导	10	1.187	0.592	50.11%
下载主导	11	1.114	0.434	61.06%
下载主导	12	1.058	0.425	59.82%
下载主导	13	1.077	0.458	57.48%
下载主导	14	1.090	0.433	60.29%
下载主导	15	1.051	0.464	55.86%
下载主导	16	1.047	0.450	57.01%
下载主导	17	1.081	0.424	60.78%
下载主导	18	1.086	0.467	57.03%
下载主导	19	0.984	0.425	56.85%
下载主导	20	1.055	0.460	56.37%

结论

- **均衡流水线**：staged 中位耗时缩短 30.44%。
- **API 主导**：staged 中位耗时缩短 15.78%。
- **下载主导**：staged 中位耗时缩短 57.46%。

模拟实验用于隔离调度算法的影响：若 staged 在均衡或下载主导场景中加速，说明分阶段信号量能够减少整篇论文占槽造成的队头阻塞；若 API 主导场景收益很小，则说明总结并发度相同会限制最终收益。

实验限制

- `asyncio.sleep` 和 `time.sleep` 只能模拟耗时，不能复现真实网络协议、服务端限流和 PDF 解析负载。
- Windows 线程调度和计时精度会产生少量波动，因此以 20 轮中位数而不是单轮结果判断。
- 模拟实验只能证明调度机制在给定工作负载下的效果，真实端到端结论仍应以真实 Benchmark 为准。
- 三种场景均在同一进程中顺序运行，不同时执行两种模式。